



陳星伃

AI 應用開發 全端系統開發 LLM / RAG Python / FastAPI 雲端部署

睿思智慧股份有限公司 | Data Engineer (AI Team - Tech Lead)

RENNES SCHOOL OF BUSINESS (法國) | Data & Business Analytics 碩士畢業

新北市泰山區 | 2~3年工作經歷 | 希望職稱：AI Application Engineer、AI Software Engineer、Full-stack AI Engineer

- 具備 **AI 系統架構設計與 Full-stack Development** 實務經驗，能獨立完成 React／TypeScript 前端、Python／FastAPI／Node.js 後端、資料庫、AI 模型整合及雲端部署。
- 專精於 **LLM Engineering、RAG、AI Agent 與 OCR／LLM Pipeline**，具備整合地端與雲端模型、建構企業級 AI 工作流程的實戰經驗。
- 擅長解決 **LLM 推論延遲、上下文限制、模型幻覺與結構化輸出不穩** 等工程問題，運用混合檢索、批次推論、Schema Validation 及 Fallback 提升系統可靠性。
- 熟悉 **GCP、AWS、Docker、PostgreSQL 與 API Architecture**，具備 AI 應用從 PoC、MVP 到正式環境部署與維運的完整經驗。
- 現任 **AI Team Tech Lead**，負責技術規劃、跨部門協作與系統架構，曾獨立完成政府文件智能審查及協會 Hybrid AI 平台的端到端開發與交付。

個人資料	女 、 25歲
就業狀態	在職中
主要手機	
E-mail	ariel512305@gmail.com
通訊地址	
英文姓名	Luna
聯絡方式	Email
駕駛執照	普通重型機車駕照 、 普通小型車駕照
交通工具	普通重型機車

學歷

RENNES SCHOOL OF BUSINESS(法國) 2023/9~2025/6

Data & Business Analytics | 碩士畢業

輔仁大學 2019/9~2023/6

統計科學學系 | 大學畢業

新莊高中 2016/9~2019/6

普通高中 | 高中畢業

工作經驗

總年資 **2~3年工作經歷**

REAS

Data Engineer (AI Team - Tech Lead)

2024/6~仍在職

睿思智慧股份有限公司（電腦軟體服務業 1~30人）

AI工程師｜新北市板橋區

Leadership & Project Management｜技術領導與專案管理

- 帶領 **AI／Data Engineer 團隊**，負責技術規劃、系統架構設計、任務分配與開發指導，推動 AI 專案從 PoC、MVP 至正式部署。
- 主導跨部門需求訪談及技術討論，將商業需求轉化為系統架構、開發規格與可執行方案。
- 撰寫 BRD、系統架構與 API 技術文件，規劃專案時程、開發里程碑及資源配置，確保專案品質與交付進度。

Full-stack AI Application Development｜全端 AI 應用開發

- **獨立負責企業級 AI 應用系統的端到端開發**，涵蓋需求分析、系統架構、前後端實作、資料庫設計、AI 整合、測試及正式部署。
- 使用 **React、TypeScript、JavaScript** 建構前端介面，搭配 **Python／FastAPI／Flask、Node.js** 開發 RESTful API 與後端服務。
- 整合 PostgreSQL、Supabase、SQL／NoSQL 與第三方 API，實作資料處理、身份驗證、角色權限、檔案管理及非同步工作流程。
- 獨立完成**人民團體文件智能審查平台**與 **AIAA 協會會務暨 AI 應用平台**，具備從系統設計到部署維運的完整實務經驗。

AI & LLM Systems Engineering｜大型語言模型與 AI 系統設計

- 設計與開發 **RAG、AI Agent、Workflow Automation** 及 OCR／LLM 文件智能處理系統，將生成式 AI 整合至企業實際業務流程。
- 建構 **Hybrid AI Architecture**，整合地端 Ollama／Gemma 與雲端 Vertex AI／Gemini／Claude，依任務需求評估模型能力、延遲、成本及隱私。
- 設計 **Vector Search、BM25、RRF、Reranking** 混合檢索流程，搭配 Prompt Engineering、Structured Output 與 Schema Validation，提高資料檢索及模型輸出的可控性。
- 導入 Human-in-the-loop、工具呼叫、規則引擎及 Fallback 機制，使 AI 產生的結果可驗證、可追溯並支援人工覆核。

LLM Pipeline Optimization｜模型效能與可靠性優化

- 針對 LLM **長上下文限制、推論逾時、幻覺、JSON 輸出不穩定及 OCR 誤差**，設計分段處理、局部上下文、批次推論、輸出驗證與多層降級機制。
- 將確定性資料解析與計算交由本地程式執行，LLM 聚焦於語意判斷與非結構化內容理解，降低不必要的模型呼叫。
- **效能成果**： 在政府文件章程比對的特定測試案例中，將第一輪 LLM 呼叫由 36 次降至 1 次，階段耗時降低 **84.8%**，完整流程耗時降低 **44.2%**。

Data Engineering & Cloud Infrastructure｜資料工程與雲端部署

- 設計 ETL、資料清洗、文件解析與模型推論管線，整合 PostgreSQL、MySQL、Supabase 與外部資料來源，支援結構化資料查詢及自動化分析。
- 使用 **GCP（Compute Engine、Cloud Run、Cloud SQL、Vertex AI）與 AWS** 進行 AI 應用部署、服務整合及基礎架構管理。
- 透過 **Docker、Docker Compose、Caddy** 建立容器化與服務部署環境，並實作背景 Worker、健康檢查、錯誤日誌、重試及監控機制。
- 建立模組化 API、資料驗證、權限控管及自動化測試，提升系統可維護性、可靠性與後續擴充能力。

核心技術： Python、FastAPI、Flask、React、TypeScript、JavaScript、Node.js、SQL、PostgreSQL、Supabase、GCP、AWS、Docker、Vertex AI、Ollama、RAG、AI Agent、OCR、LLM、ETL

數據分析實習生(Data Analytics Engineer Intern)

衛利生物科技股份有限公司（電腦軟體服務業 30~100人）

統計學研究員 | 新北市新店區

2023/3~2023/6
4個月

- 協助資料科學家進行資料清洗、分析、驗證
- 數據整理、匯出 EXCEL
- 數據分析軟體使用 (R 與 Python)
- 細心，對數據分析有熱誠，熟知統計模型應用
- word/ppt 文件整理

利用 R 與 Python 做資料的視覺化與統計分析，並做出統計模型進行預測及驗證。

#Python #R #統計軟體操作

求職條件

希望性質 全職工作
上班時段 日班
可上班日 錄取後一個月可上班
希望待遇 面議
希望地點 台北市、新北市、台中市
遠端工作 對遠端工作有意願

希望職稱 AI Application Engineer、AI Software Engineer、Full-stack AI Engineer
希望職類 AI工程師、全端工程師、數據分析師／資料分析師、軟體工程師、資料工程師

語言能力

英文

聽/精通 | **說/精通** | **讀/中等** | **寫/中等**

法文

聽/略懂 | **說/略懂** | **讀/略懂** | **寫/略懂**

台語

中等

資格認證

護理照顧相關證照

CPR證照

中華民國紅十字會

TQC+

網頁資料擷取與分析 Python

基礎程式設計 Python

基礎程式語言

其他

經濟部初級巨量資料分析師

iPAS經濟部產業人才能力鑑定

更多資格認證

AWS training and certification - Gen AI Application Development (GCR Only) TQC+ 程式語言 Python 3（專業級） SPSS 商業數據分析師認證 標準級通過 Datacamp

專長

AI 應用與 LLM 系統開發

• 獨立設計與開發端到端 AI 應用系統，涵蓋架構規劃、模型整合、API、測試及部署。
• 建置 RAG、AI Agent、Workflow 與 OCR／LLM 文件智能處理流程。
• 整合 Ollama、Gemma、Vertex AI、Gemini、Claude 等地端與雲端模型。
• 導入 Prompt Engineering、Structured Output、Schema Validation 及 Human-in-the-loop。

#LLM #GenerativeAI #AIApplication #RAG #AIAgent #VertexAI

#LLM #AI #語言模型 #深度學習 #演算法設計 #自然語言處理 #生成式AI #Machine Learning #AI圖像生成

全端系統與 RESTful API 開發

• 使用 React、TypeScript、JavaScript 建構互動式前端及管理平台。
• 以 Python／FastAPI／Flask、Node.js 開發 RESTful API 與模組化後端。
• 整合 PostgreSQL、Supabase、MySQL，設計資料模型、身份驗證及角色權限。
• 獨立完成前後端、資料庫、第三方服務與 AI 模型整合。

#Python #FastAPI #React #TypeScript #NodeJS #PostgreSQL

#Git #Github #PostgreSQL #Python #資料庫程式設計 #MS SQL #JavaScript #資料庫系統管理維護 #模組化系統設計 #ReactJS

RAG、AI Agent 與模型效能優化

• 設計 Vector Search、BM25、RRF、Reranking 混合檢索流程。
• 針對 LLM 上下文限制、推論逾時、幻覺及 JSON 格式不穩，導入分段、批次推論與 Fallback。
• 使用 Pydantic Schema、規則引擎與確定性資料解析驗證模型結果。
• 實測章程比對第一輪模型呼叫由 36 次降至 1 次，該階段耗時減少 84.8%（特定測試案例）。

#RAG #VectorSearch #BM25 #PromptEngineering #LLMOps

#PyTorch #tensorflow #Keras #深度學習 #機器學習 #scikit-learn #Machine Learning #NLP #OpenCV #影像辨識

Data Engineering 與 AI Pipeline

Cloud Infrastructure 與系統部署

Computer Vision 與 AI 系統品質

• 使用 Python、SQL 設計 ETL、資料清洗、轉換及模型推論管線。
• 處理 PDF、DOCX、ODT、Excel 與圖片等資料，整合 OCR 及原生文字解析。
• 建立非同步背景 Worker、批次處理、進度追蹤及失敗重試流程。
• 使用 PostgreSQL、MySQL、pgvector、DuckDB 支援資料查詢、檢索與分析。

#DataEngineering #ETL #DataPipeline #OCR #SQL #Python

#ETL #Data Architect #Python

• 使用 GCP Compute Engine、Cloud Run、Cloud SQL、Cloud Storage、Vertex AI 部署與整合 AI 應用。
• 使用 Docker／Docker Compose、Caddy 建立容器化與 HTTPS 反向代理環境。
• 具備 AWS、Supabase 及 Cloudflare Workers／D1 Serverless 部署經驗。
• 建置背景服務、健康檢查、錯誤紀錄、監控及權限管理，支援正式環境維運。

#GCP #AWS #Docker #CloudRun #Cloudflare

#AWS #Google Cloud #Microsoft Azure #CI/CD #PostgreSQL #Github

• 使用 Python、OpenCV、SIFT／FLANN、Affine Transformation 開發影像對齊與穩定化流程。
• 實作 Laplacian 模糊偵測、重疊裁切分析及縮時影片自動生成。
• 建立 API 資料驗證、自動化測試、錯誤處理及執行紀錄。
• 撰寫技術文件與系統架構說明，具備跨層除錯及完整產品交付能力。

#OpenCV #ComputerVision #VideoProcessing #Testing #SystemDesign

#OpenCV #Computer Vision #影像辨識 #Test Scripts

專案成就

人民團體文件智能審查平台｜Government Document Intelligence Platform

獨立負責 AI 文件審查平台的系統架構、前後端開發、AI Pipeline、資料庫設計及部署，整合 OCR、LLM 與規則引擎，支援章程修正比對、跨表單一致性檢核、理監事簡歷冊辨識及法規疑義審查。

- 採用 React、TypeScript、FastAPI、PostgreSQL、TWCC COS 與 Vertex AI Claude／Gemini，建立多格式文件解析與非同步處理架構。
- 設計原生文字優先、OCR Fallback、規則式解析、LLM 語意判斷與 Pydantic Schema 驗證流程，降低模型幻覺及格式錯誤。
- 導入相似度預篩、批次推論與局部上下文，減少不必要的 LLM 呼叫及長文件推論延遲。
- 建立背景 Worker、任務重試、進度追蹤、稽核紀錄與人工覆核機制。

成果｜LLM 推論效能與文件審查可靠性優化

- **推論效率優化：** 透過相似度預篩與批次推論，將章程比對第一階段 LLM 呼叫次數由 **36 次降至 1 次（減少 97.2%）**，推論耗時由 **201.2 秒縮短至 30.6 秒（減少 84.8%）**。
- **端到端流程效能：** 將完整文件審查流程由 **480.3 秒縮短至 268.2 秒（減少 44.2%）**，改善長篇文件處理效率。
- **結果可靠性：** 於該測試案例維持 **4/4 標準答案召回**，並結合 Schema Validation、Fallback 與 Human-in-the-loop，建立可驗證、可追溯的審查流程。

技術： Python、FastAPI、React、TypeScript、PostgreSQL、Vertex AI、Claude、Gemini、OCR、Docker、Pydantic

AIAA 協會會務暨 AI 應用平台｜Full-stack & Hybrid AI Platform

獨立負責協會數位營運平台的系統架構、前後端開發、資料庫設計、AI 模型整合及 GCP 部署，建立整合公開官網、會員中心與會務管理後台的一體化系統，涵蓋會員審核、活動報名、會議、投票、文件與通知管理，並導入地端與雲端混合式 AI 架構。

- 採用 **React、Node.js、Supabase 與 GCP Compute Engine** 建構模組化全端系統，整合 PostgreSQL、Auth、Storage、RLS 與角色權限管理，支援公開、會員及管理後台的不同資料存取需求。
- 整合 **NVIDIA GX10／Ollama／Gemma 地端 LLM** 與 Google Cloud Vertex AI、Speech-to-Text，實作中英日即時字幕、錄音轉錄、長篇會議摘要、決議與待辦事項擷取，以及議程和 PowerPoint 簡報生成。
- 針對長篇逐字稿、LLM 幻覺、JSON 輸出不穩與即時翻譯延遲，導入 **Map-Reduce 階層式摘要、Schema Validation、專有名詞表、Timeout／Fallback 與 Human-in-the-loop** 審核機制。
- 使用 **Caddy、SSE、背景 Worker 與 GCP 監控機制**，實作 HTTPS 反向代理、即時字幕推送、失敗重試、健康檢查與操作稽核，支援正式環境部署及維運。

成果｜全端平台工程、混合式 AI 架構與系統可靠性

- **端到端平台架構與交付：** 獨立主導協會數位平台從系統設計、前後端開發、資料模型建構至 GCP 正式環境部署的完整開發流程。採用模組化單體架構整合會員、活動及會務管理服務，系統涵蓋 **43 個前端路由、48 支資料庫 Migration**，建立具備權限隔離、資料一致性與後續擴充能力的應用架構。
- **Hybrid AI Architecture 與業務流程整合：** 建立 **On-Premise LLM + Cloud Speech AI** 混合式推論架構，整合中、英、日三語即時字幕、長篇逐字稿摘要、會議決議擷取及文件生成。透過階層式摘要、結構化輸出驗證與 Human-in-the-loop 審核，將生成式 AI 納入可控的正式會務流程，降低模型幻覺及非預期輸出帶來的作業風險。
- **系統韌性與品質驗證：** 設計涵蓋模型推論逾時、服務異常、輸出格式錯誤及即時連線中斷的多層 Fallback 機制，並結合非同步背景工作、角色權限、操作稽核與服務監控，強化系統可維運性與故障處理能力；現行版本 **81 項自動化測試全數通過（81/81）**。

技術： React、JavaScript、Node.js、Supabase、PostgreSQL、GCP Compute Engine、Vertex AI、Ollama、Gemma、Speech-to-Text、SSE、PWA、Caddy

NeuroSme Private Hub｜Enterprise Private AI Agent & RAG Platform

參與企業私有化 AI 平台的系統架構與全端開發，整合多模型管理、知識庫 RAG、AI Agent、視覺化 Workflow、多租戶權限及 On-Premise 部署，協助企業將生成式 AI 整合至內部知識查詢、資料分析與自動化業務流程。

- 採用 **React、TypeScript、FastAPI、PostgreSQL／pgvector、DuckDB 與 Docker** 建構模組化 AI 平台，支援企業多租戶資料隔離、API 整合及地端／雲端模型切換。
- 設計 **Vector Search + BM25 + Reciprocal Rank Fusion（RRF）+ Cross-Encoder Reranking** 多階段 RAG 檢索流程，先進行混合召回，再將候選內容收斂為高相關證據，減少不必要的模型上下文。
- 建立 **LLM Intent JSON → Pydantic Schema Validation → SQL Generation → DuckDB Execution** 分層資料分析流程，將語言理解與確定性運算分離，避免直接執行 LLM 自由生成的 SQL。
- 整合 **AI Agent、Tool Calling、Workflow Engine、Human-in-the-loop 與模型路由機制**，支援流程分支、人工審核、執行追蹤及企業內部系統串接。

成果｜企業 AI 架構與模型可靠性設計

- **RAG 檢索架構：** 建立混合檢索與二階段排序流程，整合語意召回及精確關鍵字查詢，並將最多 50 個候選片段收斂至最多 6 段相關證據，以控制生成模型的上下文輸入。
- **AI 資料分析可靠性：** 透過結構化 Intent、Schema Validation 與 DuckDB 確定性運算，將模型的語意理解能力轉換為可驗證、可測試的資料分析流程。
- **企業系統整合：** 支援多租戶、雲端／地端模型路由、API Key、Workflow Execution 與 Human-in-the-loop，建立具備模型替換彈性、流程追蹤及故障降級能力的企業 AI 平台。

技術： Python、FastAPI、React、TypeScript、PostgreSQL、pgvector、DuckDB、RAG、BM25、RRF、Cross-Encoder、Ollama、LiteLLM、Docker

---

影像處理與縮時影片生成系統｜Computer Vision & Time-Lapse Video Processing

開發自動化影像處理與縮時影片生成系統，運用 Computer Vision 技術解決長時間攝影造成的影像位移、畫面晃動、模糊影格與裁切不一致問題，建立從影像輸入、特徵匹配、幾何校正、品質篩選到影片輸出的自動化處理流程。

- 使用 **Python／OpenCV 的 SIFT 特徵偵測與 FLANN 特徵匹配**，搭配 Affine Transformation 估計影像間的幾何變換，完成多張影像自動對齊。
- 分析多幀影像經幾何校正後的有效重疊區域，自動計算一致的裁切範圍，避免影片生成後出現黑邊及不規則視角變化。
- 透過 **deque 歷史轉換矩陣與加權平滑機制**，降低連續影格間的平移抖動，改善縮時影片的視覺穩定性。
- 使用 **Laplacian Blur Detection** 評估影格清晰度並篩除模糊影像，整合可配置 FPS、MJPG 格式輸出及即時影像預覽。

成果｜影像處理自動化與影片品質優化

- **影像對齊自動化：** 建立特徵匹配與仿射轉換流程，自動完成大量連續影像的幾何校正，減少人工逐張對齊需求。
- **影片穩定性與品質：** 整合重疊區域裁切、轉換矩陣平滑及模糊影格過濾，改善畫面晃動、黑邊與影像品質不一致問題。
- **完整影像處理 Pipeline：** 實作從原始影像讀取、校正、品質篩選到縮時影片生成及預覽的端到端流程，支援工程進度記錄與長時間攝影應用。

技術： Python、OpenCV、SIFT、FLANN、Affine Transformation、NumPy、Laplacian Blur Detection、Video Processing、MJPG

<Personal Side Project> BraveTalk Club｜AI English Speaking & Travel Collaboration PWA

獨立設計、開發與部署 AI 英語口說及雙人旅行協作 PWA，以 TOEIC 600／CEFR A2–B1 學習者為目標，整合情境教材、AI 角色扮演、模擬面試、瀏覽器語音辨識、學習紀錄與雙人共享旅行規劃功能，建立可跨裝置使用的完整產品。

- 採用 **JavaScript、Cloudflare Workers、D1、Static Assets 與 Workers AI** 建構 Serverless PWA，並將原本 Node.js／SQLite／Ollama 本機架構遷移至雲端，改善跨裝置存取與部署維運限制。
- 建立 **76 個情境課程、304 組核心字句**，整合 AI 情境對話與模擬面試回饋，透過 Prompt Engineering、上下文裁切、Token Budget 與固定輸出格式控制模型回應。
- 使用 **Web Speech Recognition 與 MediaRecorder** 實作瀏覽器端語音轉文字、文字吻合度及錄音回放，明確區分文字模型與語音分析能力，避免產生不可靠的發音評分。
- 實作 **HttpOnly Cookie Session、PBKDF2-SHA256、資料隔離、登入限流、AI 使用配額與 Fallback**，並設計固定教材與協作功能不依賴 LLM 的降級架構。

成果｜Serverless 產品交付與 AI 服務可靠性

- **端到端產品開發：** 獨立完成涵蓋 **8 個課程分類、76 個情境課程與 304 組核心字句** 的 AI 學習平台，並整合共享行事曆、旅行計畫、票券、清單、共同目標與私人筆記。
- **雲端架構遷移：** 將本機 Node.js／SQLite／Ollama 遷移至 Cloudflare Serverless 架構，實現跨裝置使用，並保留原有本機開發與替代模型路徑。
- **AI 成本與可靠性控制：** 透過最近 10 則對話保留、600-token 輸出上限、訪客每日配額及 AI 降級設計，限制模型用量，確保生成式 AI 不可用時，核心學習與協作功能仍能運作。
- **自動化測試：** 建立課程完整性、雙帳號資料隔離、訪客權限與協作流程測試，現行版本通過 **7/7 項自動化測試**。

技術： JavaScript、Node.js、Cloudflare Workers、Cloudflare D1、Workers AI、Gemma、SQLite、Ollama、PWA、Web Speech API、MediaRecorder、Service Worker

附件



www.linkedin.com/in/singyu-chen-227994282/

Linkedin



singyu0118.github.io/singyu_cv/

SingYu - AI Engineer Portfolio



starfish-minmin-0920.singyu-bravetalk.workers.dev/

BraveTalk Club｜AI English Speaking & Travel…